

Systèmes de recommandation

IA générative.

L'utilisation de l'IA générative est recommandée pour ce TP.

Ce TP a pour objectif la conception d'un système de recommandation sur la base de données Kaggle "Movies dataset".

Exercice 1. Chargement des données.

- 1) Récupérer sur Kaggle et charger les fichiers suivants du dataset : `movies_metadata.csv`, `ratings_small.csv` et `links_small.csv`.
- 2) Afficher un aperçu de chaque table et vérifier leur compréhension.
- 3) Combien d'utilisateurs y a-t-il ? De films ? D'avis ?
- 4) Quelle est l'utilité du fichier `links_small.csv` par rapport aux deux autres fichiers ?
- 5) Nettoyer la table `movies_metadata.csv` : Convertir tous les ID de films au format numérique (en retirant les films dont les ID ne sont pas numériques), ne conserver qu'une ligne par ID unique.
- 6) Nettoyer la table `ratings_small.csv` : Retirer les avis manquants et les ID d'utilisateurs et de films non conformes, et convertir tous les ID d'utilisateurs et de films au format numérique.
- 7) Déterminer les 10 films les plus anciens du dataset.
- 8) Déterminer les 10 films ayant eu le plus gros succès au box-office (colonne `revenue`).
- 9) Nous aurons besoin d'une séparation entraînement/test pour tester nos modèles. Que faut-il séparer en deux ? Effectuer une séparation entraînement/test de sorte à ce que chaque utilisateur en test ait une chance de recevoir de bonnes recommandations. Comment avez-vous fait ?

Exercice 2. Un bon système de filtrage collaboratif.

Chargeons-nous dans un premier temps de concevoir un système de filtrage collaboratif user-based, simple mais efficace.

- 1) Choisir une mesure de similarité et un nombre de voisins.
- 2) Calculer une matrice des avis utilisateur/films. Celle-ci sera creuse (de très nombreuses valeurs manquantes). Comment l'imputer ?
- 3) Concevoir un système de filtrage collaboratif user-based. L'entraîner sur la base d'entraînement et le tester sommairement :
 - vérifier qu'il parvient à donner des avis pour un utilisateur donné,
 - afficher les noms des films préférés d'un utilisateur au hasard et les films qu'il recommande, et vérifier la cohérence des recommandations.
- 4) S'assurer qu'aucune fuite de données n'est présente dans votre code.
- 5) Calculer sur l'ensemble de test la RMSE et la MAE.

Exercice 3. Évaluation.

Afin de comparer nos modèles entre eux, il vaut mieux posséder des métriques qui ont du sens vis-à-vis de notre application.

- 1) Rechercher rapidement ce que signifient les termes "Précision top k", "Rappel top k" et "NDCG top k". Pourquoi ces métriques sont plus intéressantes pour notre cas pratique ?
- 2) Implémenter des fonctions pour calculer ces métriques à partir d'un système de recommandation donné et d'un ensemble de test.
- 3) Calculer la précision top 10, le rappel top 10 et le NDCG top 10 du système de recommandation que vous avez conçu. Si l'une de ces métriques vaut 0, c'est qu'il existe des erreurs dans votre code...

Exercice 4. Améliorations.

- 1) Optimiser les hyperparamètres de votre système de filtrage collaboratif user-based. Vous présenterez vos résultats dans un tableau et sélectionnerez avec justification le système qui vous semble être le meilleur. Vous commenterez la stabilité (ou l'instabilité) de vos résultats en fonction des variations des hyperparamètres.
- 2) Implémenter l'une des modifications suivantes au choix et les comparer avec votre système :
 - le filtrage des utilisateurs trop peu actifs dans la base d'entraînement avant d'entraîner,
 - le centrage des notes par utilisateur avant le calcul de similarité,
 - le passage à un système de filtrage collaboratif item-based.

Exercice 5. Analyse critique.

Justifier chaque réponse qui s'y prête à l'aide d'arguments numériques.

- 1) Votre système favorise-t-il les films populaires ? Estimez-vous que c'est une bonne chose ?
- 2) Les recommandations faites pour un utilisateur sont-elles diverses ?
- 3) Les recommandations faites au global sont-elles diverses ?
- 4) Les recommandations sont-elles réellement personnalisées ?
- 5) Comment amélioreriez-vous votre système en production ?